淡江大學人工智慧學系

114 學年度專題成果報告

專題名稱：**強化學習在自駕車系統之應用**

組員:

姓名	學號
莊正綸	412770322
陳廷祐	412770835
徐子洋	412771387

組別：2-3 組

指導老師：王銀添 教授

中華民國　115　年　6　月

目錄

壹、 序論 1

1.1. 研究動機 1

1.2. 研究目的 1

1.3. 研究範圍 1

1.4. 研究貢獻 1

貳、 文獻探討 3

1. 自動駕駛技術概述 3

2. CARLA 模擬環境分析 3

3. 強化學習在自動駕駛中的應用 3

4. 深度強化學習於自動駕駛之應用 4

5. DVS 事件相機與神經型態視覺概述 5

參、 強化學習（Reinforcement Learning） 7

3.1. 自駕車深度強化學習(ADC-DRL)架構 7

3.1.1 近端策略最佳化強化學習演算法 7

3.1.2 模型架構與端到端訓練收集過程 8

3.1.3 神經網路參數更新機制 (Neural Network Optimization) 9

3.1.4 基礎獎勵設計 (Base Reward Design) 13

3.2 剎車機制設計 14

3.2.1 剎車動作設計 14

3.2.2 油門與剎車互斥設計 15

3.3 紅燈偵測與動作設計 15

3.3.1 紅燈偵測 15
3.3.2 紅燈情況下獎勵機制設計 15
3.4 問題分析 16
3.5 實作結果 17
3.6 軟硬體設備 20
肆、 VAE 視覺影像資訊獲取與壓縮 21
4.1. 傳統影像處理-邊緣檢測與霍夫變換 21
4.2. LaneNet 道路線分割模型 21
4.3. VAE（Variational Autoencoder，變分自編碼器） 22
4.4. 問題分析 23
4.5. 實作結果 23
伍、 DVS 事件相機與自動緊急煞車系統（AEB） 25
5.1. 視覺感測與技術探索 25
5.2. 幾何測距與動態控制演算法 28
5.3. 物件追蹤與速度濾波 29
5.4. 行駛走廊過濾與切入偵測 29
5.5. TTC 動態決策與遲滯狀態機（Hysteresis State Machine） 30
5.6. 數據降維與鳥瞰圖儀表板設計 30
5.7. 問題分析 31
5.8. 實作結果 31
陸、 整合 36

6.1. 問題分析 36

6.2. 系統架構 36

6.3. 結果呈現 37

柒、 結論 38

捌、 參考文獻 39

壹、 序論

1.1. 研究動機

自動駕駛能降低交通事故並提升交通效率。然而，傳統規則型系統難以應對未知與複雜動態路況。此外，雖然事件相機（DVS）與脈衝神經網路（SNN）具備極佳的防碰撞潛力，但實務上存在訓練不穩定與閉環控制高延遲的瓶頸。在多模組整合方面，主動巡航與被動防護系統也常面臨控制權爭奪的衝突。因此，開發一套具備高環境適應力，且能平滑交接雙系統控制權的自駕決策系統為本研究之核心動機。

1.2. 研究目的

本專題旨在透過 CARLA 模擬器，開發一套結合「主動決策」與「被動防護」的雙腦協同自駕系統。主動決策導入強化學習 PPO 演算法，實現端到端的車道置中與紅燈煞停；被動防護則開發基於 YOLO26 的純視覺自動緊急煞車系統(AEB)，以幾何測距與碰撞時間(TTC)預測取代光學雷達。最終目標是成功整合雙系統，實現平滑且零震盪的權限交接。

1.3. 研究範圍

本專題的開發與閉環驗證均建構於 CARLA 模擬器之上。強化學習模組將車輛動態、導航與 VAE 壓縮之視覺特徵融合為 97 維狀態空間，輸出連續型動作控制。AEB 模組則以 YOLO26 為感知核心，搭配逆透視投影矩陣（IPM）建構鳥瞰圖（BEV）儀表板。測試情境涵蓋常規巡航、動態避障、號誌應對以及無預警切入（Cut-in）等複雜動態交通場景。

1.4. 研究貢獻

陳廷祐（強化學習決策模組）(35%)： 負責 PPO 演算法優化與自駕決策訓練。引入指數平滑濾波（EMA）減少方向盤輸出的震盪，並設計「複合型乘法獎勵機制」，調整模型對車速與車道置中的取捨。此外，將動作空間擴展至 3D 並加入油煞互斥，配合 30% 機率的強制紅燈訓練，測試模擬器號誌資訊下的減速與停車行為。

莊正綸（VAE 視覺資訊獲取與壓縮）（30%）： 負責感知數據的降維與特徵萃取。將複雜的前視相機影像透過變分自編碼器（VAE）極致壓縮為 64 維潛在空間（Latent Space）向量，在保留關鍵道路幾何與障礙物特徵的前提下，顯著降低了後端控制模型的計算負載。同時搭配 LaneNet 模型實現精準的車道分割與非線性聚類。

徐子洋（純視覺 AEB 自動緊急煞車系統）（35%）： 負責被動防護系統的建構與雙腦整合。以 YOLO26 為感知核心，捨棄車寬改採「車輛實體高度」進行高穩定度的幾何測距，並加入 IoU 跨幀追蹤以降低雜訊。更設計了非對稱的 TTC 遲滯狀態機，徹底解決煞車反覆切換的震盪問題，實現緊急狀態下平滑且無縫的控制權接管。

貳、 文獻探討

1. 自動駕駛技術概述

近年來，自動駕駛技術發展迅速，從最初的輔助駕駛系統演進至今日的高度自動化。SAE（SAE International，國際汽車工程師學會）將自動駕駛技術劃分為 L0 至 L5 共六個等級，目前大多數商用系統仍處於 L2-L3，而完全自動駕駛（L4-L5）則仍面臨諸多技術與法規挑戰。推動自動駕駛的核心目標之一，是降低人為錯誤導致的交通事故。

根據 [1]，自動駕駛技術可望提升行車安全性、緩解交通擁堵、減少碳排放，並重新分配駕駛時間。此外，它也能改善行動不便者的交通方式，並帶動新興產業發展，如交通行動服務（MaaS）與智慧物流。自動駕駛技術不僅是未來交通發展的重要方向，更可能對社會帶來深遠影響。

2. CARLA 模擬環境分析

CARLA 作為目前最先進的自動駕駛模擬器之一，根據 [2] 的研究指出，其具備了高度擬真的動態交通模擬能力。該平台內建真實的車輛運動學與物理引擎，並可生成大量具備自主行為的車輛與行人，從而精準還原壅塞、違規及突發狀況等複雜的動態交通場景。在感測與數據收集方面，CARLA 支援常規的攝影機、光學雷達（LiDAR）、毫米波雷達，以及高階的動態視覺感測器（DVS）與語意分割鏡頭，且系統能同步輸出完美的真值（Ground Truth）數據，極大有利於多模態感測模型的訓練。

此外，該模擬器具備動態天氣與極端環境控制功能，允許開發者透過程式精細調控降雨、起霧及光照強度等環境變數，輕易重現強烈逆光或夜間低照度等極端光源條件，這對於測試感知系統的強健性至關重要。最後，CARLA 提供了強大的 Python API 以實現高擴展性與演算法整合，給予開發者對環境物件的絕對控制權，並能與主流的強化學習（RL）等機器學習框架無縫對接，大幅提升了自動駕駛演算法的開發與閉環測試效率。

3. 強化學習在自動駕駛中的應用

強化學習作為自動駕駛領域的核心技術，展現出多項顯著的應用優勢。首先，在端到端

學習方面，Chen 等人 [3] 提提出的強化學習框架能直接將感測器輸入映射為控制指令，使模型得以直接從收集到的資料中學習關鍵特徵，進而更有效地應對複雜的環境變化。這種自主特徵萃取的能力，成功擺脫了傳統模組化架構（如感知、定位、決策、執行）中過度依賴人工設計規則的限制，讓模型能透過與環境的動態互動，自主捕捉並理解交通流的運行邏輯。

在決策層面上，強化學習採用「試錯（Trial-and-Error）」機制，賦予車輛在錯綜複雜的動態交通環境中進行連續決策與長期規劃的能力，使其能精準預判周圍車輛意圖並做出長遠駕駛規劃。此外，透過客製化的獎勵函數設計，系統能夠達成多目標平衡優化，同時兼顧「行車安全」、「法規遵循（如不逆向、不越線）」與「乘客舒適度」等多重駕駛指標。綜上所述，強化學習模型具備極高的高動態環境泛化力，在面對惡劣氣候（如暴雨、大雪）或未曾見過的突發路況時，能展現出遠勝於傳統規則型系統的適應力與魯棒性。

4. 深度強化學習於自動駕駛之應用

隨著深度學習與強化學習技術的結合，深度強化學習（Deep Reinforcement Learning, DRL）已成為解決自動駕駛連續控制問題的核心技術之一。DRL 允許車輛（Agent）在虛擬模擬環境中透過試錯機制與環境動態互動，無需依賴繁複的人工標註規則或傳統模組化架構，即可自主學習出從感測器輸入到控制指令輸出的最佳決策策略。這種端到端的學習架構，大幅提升了模型在面對未知動態路況時的泛化能力與環境適應力。

根據 Shaikh 等人基於 CARLA 模擬器之開源自駕車研究 [7]，該文獻具體展示了如何運用深度強化學習演算法進行自動駕駛的端到端閉環控制。該研究將車輛前視攝影機的 RGB 原始影像作為高維度狀態輸入，透過卷積神經網路（CNN）萃取空間特徵後，結合強化學習演算法輸出方向盤轉角與油門等連續控制訊號。同時，該研究透過精心設計的獎勵函數，包含鼓勵車輛維持目標巡航速度、懲罰偏離車道與發生碰撞等負面行為，成功引導神經網路模型學會在複雜的模擬城市中進行車道保持與安全避障。此文獻不僅驗證了 DRL 在高擬真環境中取代傳統控制演算法的可行性，其直接將影像特徵映射至動作空間的架構設計，也為後續結合潛在空間壓縮（如 VAE）與進階演算法（如 PPO）的自駕決策系統奠定了重要的實務與理論基礎。

為進一步落實並加速上述進階演算法在自駕系統中的開發，建構穩定且標準化的訓練環境至關重要。Maté [8] 所開發的開源環境框架，成功將 CARLA 模擬器與目前廣泛應用的強化學習函式庫 Stable Baselines3 (SB3) 進行深度整合。該研究將 CARLA 複雜的感測器數據串流與車輛控制介面，封裝為標準化的環境 API，使開發者能無縫導入 SB3 中經過嚴格驗證的演算法（如 PPO 或 SAC）進行模型訓練。此框架的引入不僅大幅降低了端到端自駕模型訓練的工程門檻，其具備的模組化與高擴充性特徵，也為後續整合新型感測模態（例如動態視覺感測器 DVS 事件資料）或設計更複雜的連續動作空間，提供了理想的實作與效能驗證平台。

5. DVS 事件相機與神經型態視覺概述

事件相機（DVS, Dynamic Vision Sensor）模仿生物矽視網膜機制，採非同步運作方式：僅在像素亮度變化超越閾值時，才輸出帶有微秒級時間戳、座標與極性的事件（Event）。正極性事件（ON Event, +1）對應像素變亮，負極性事件（OFF Event, −1）對應像素變暗 [4]。相較於傳統 RGB 相機的固定幀率輸出，DVS 具備極高時間解析度（微秒級）、高動態範圍（HDR）、極低功耗，以及天然去除靜態背景的特性，非常適合高速行駛與突發碰撞預警場景。

在處理 DVS 事件流方面，脈衝神經網路（SNN, Spiking Neural Network）被認為是天然的配對架構。SNN 以「脈衝（Spike, 0 或 1）」傳遞訊號，神經元累積膜電位達閾值才發放脈衝，在事件驅動模式下實現極致節能。學習方法上，SNN 常採用 STDP（脈衝時序依賴可塑性）或替代梯度法（Surrogate Gradient）解決不可導問題。SpikeYOLO [5] 是專為事件視覺設計的目標偵測架構，基於 YOLOv8 改良，將 ReLU 激活函數替換為 I-LIF（Integrate-and-Fire）脈衝神經元，訓練期使用整數值近似穩定反向傳播，推論期採二值脈衝驅動，達到「無事件即無運算（No Event, No Computation）」的效果。

在資料模擬方面，V2E（Video-to-Events）工具 [6] 透過 SuperSloMo 時間插值與 Weber-Fechner 定律 Lin-Log 轉換，將普通影片模擬為高擬真事件流；然而因處理速度不符即時需求，本專案進一步自研輕量化 DVS 轉換算法，以 log 差分閾值觸發方式達成即時轉換。最

終因 SNN 閉環控制延遲問題，策略轉換為成熟的 YOLO26（CNN）架構，以確保系統達到生命安全級別的可靠度。

參、 強化學習（Reinforcement Learning）

為了實現車道置中、即時輔助煞停的自駕系統，本專題整合強化學習與純視覺 AEB 安全系統兩大模組，並透過模擬環境進行訓練與測試。技術架構如下：

Razak 於 CARLA 環境中所建立的自駕車深度強化學習(Autonomous Driving in Carla using Deep Reinforcement Learning, ADC-DRL) [7] 以及 Maté 將 CARLA 模擬器與主流強化學習函式庫 Stable Baselines3 進行了深度整合[8]。

3.1. 自駕車深度強化學習(ADC-DRL)架構

本專題參考 Razak 所建立的自駕車深度強化學習(ADC-DRL)架構[7]，其系統架構如圖 1 所示。此自駕車學習架構包含自駕車代理人 CARLA、影像處理模組、強化學習模組等。影像處理模組使用 Variational Auto-Encoder (VAE)模型，擷取環境影像的潛在空間(latent space)特徵，提供強化學習使用。強化學習則使用近端策略最佳化強化學習演算法(Proximal Policy Optimization, PPO)演算法。

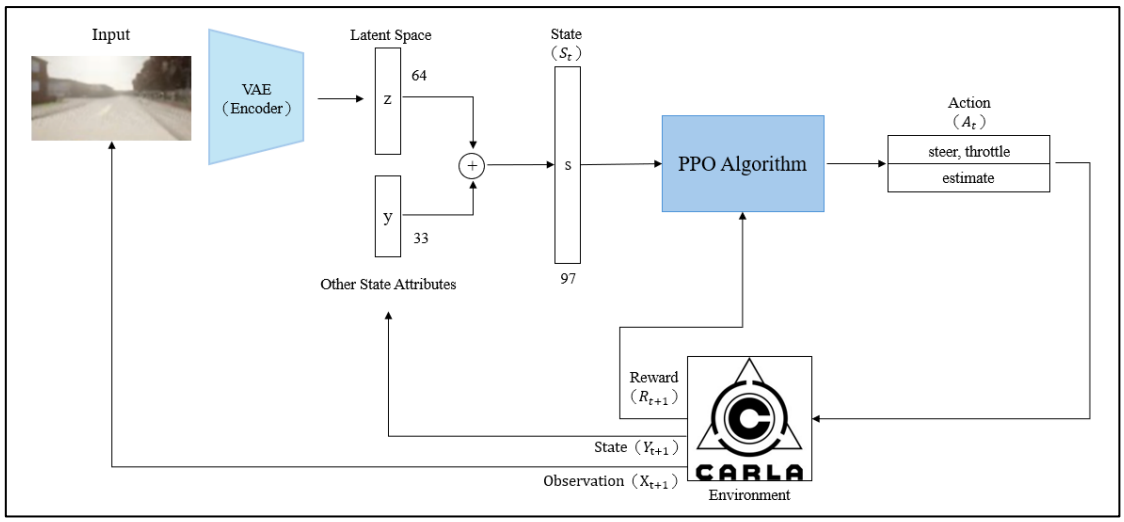


圖 1 ADC-DRL 資訊流程圖

3.1.1 近端策略最佳化強化學習演算法

近端策略最佳化強化學習演算法(PPO)是一種在強化學習領域廣泛使用的在線策略（On-policy）演算法，主要用於訓練代理（Agent）在給定環境中進行最佳決策。它能夠有效處理高維度的連續動作空間，使模型能進行更細緻的轉向與速度調整，適合應用於自動駕駛的連續控制任務。PPO 的核心概念是在保證新策略與舊策略差異不致過大的前提下，尋找性能更佳

的策略。藉此平衡訓練過程中的探索（Exploration）與利用（Exploitation）。該演算法能維持穩定訓練的關鍵，在於採用策略剪裁（Clipped Surrogate Objective）機制，當權重更新幅度過大時，系統會直接截斷新舊策略的機率比值，避免過度更新。這能有效防止模型因受到極端偏差值影響而導致策略崩潰(Policy Crash)，從而確保了模型在複雜交通情境下的收斂穩定性。

3.1.2 模型架構與端到端訓練收集過程

本系統採用 On-policy 的數據收集模式，自駕車必須直接與 CARLA 模擬環境進行即時互動。強化學習模型建構深度的 Actor-Critic 神經網路。

在每一個時間步 t，感測器模組會將視覺特徵（64 維）、車輛狀態（3 維）與導航路徑（30 維），整合成一個 97 維的狀態輸入向量 s_t。該向量首先經由共享的特徵處理流程進行整合，形成 Actor 與 Critic 皆可使用的共同輸入特徵。訓練過程中，Actor 的策略損失與 Critic 的價值損失所產生的梯度，會共同反向傳播至共享特徵處理流程，並透過 PPO 的總損失函數與 Adam 優化器更新其參數。

共享特徵處理完成後，輸出特徵會分別輸入 Actor 與 Critic 兩個獨立的決策分支。兩個分支皆由兩層全連接網路構成，第一層包含 500 個神經元，第二層包含 300 個神經元，並採用 ReLU 作為非線性激活函數。雖然 Actor 與 Critic 使用相同的輸入特徵，但兩個分支的全連接網路參數彼此獨立，分別依據策略損失與價值損失進行更新。

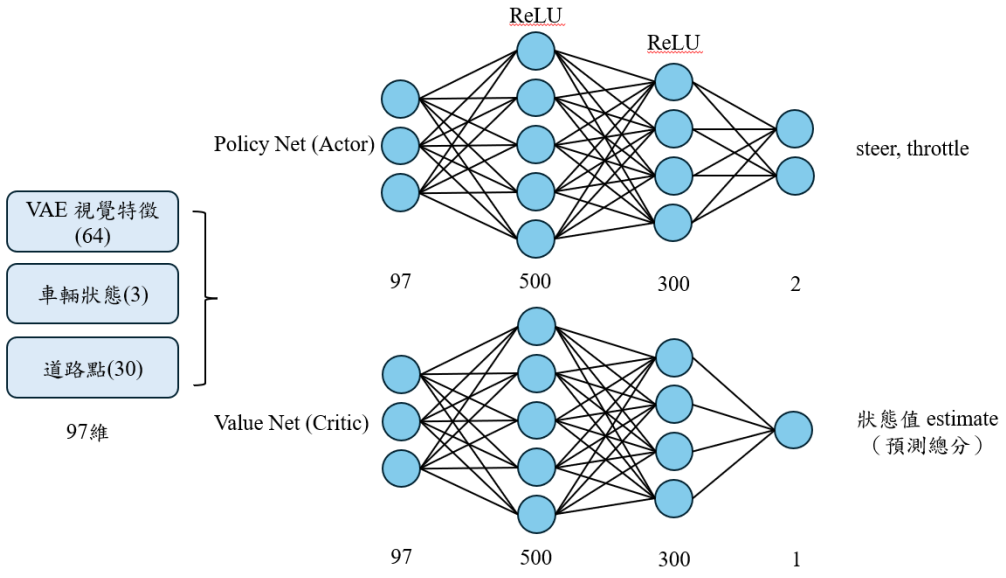


圖 2 Actor-Critic 模型架構

97 維的狀態輸入向量 s_t經過共特徵抽取器處理後，可視為代表「當下路況」的隱含向量矩陣 latent_pi，作為後續決策的輸入，進入 Actor 決策網路（策略輸出），負責將特徵映射至連續動作空間；在底層運算中，神經網路會透過最後一層的線性轉換公式

$$\mu = W \cdot \text{latent_pi} + b \tag{3.1}$$

計算出常態分佈的均值 μ，此值視為模型根據當前路況所判斷的最佳動作中心點。其中 W 為神經網路最後一層的權重矩陣，b 為偏差常數。再搭配一組獨立可訓練的標準差 σ，構成一個以 μ 為中心、σ 為範圍的常態分佈函數。Actor 網路便會據此常態分佈，隨機抽樣出 2 維的具體控制動作 a_t，對應方向盤 (Steer) 與油門 / 煞車 (Throttle) 來實質操控車輛。

97 維的狀態輸入向量 s_t經過共特徵抽取器處理後，另一路進入 Critic 網路(價值預估)，負責將相同的 300 維特徵映射為 1 維的純數值 (Scalar)，即狀態價值預估值 $V(s_t)$，用來估計當前狀態未來可獲得的累積回報。

Actor 抽樣出的駕駛動作 a_t 會實質輸入至 CARLA 模擬器中執行。環境向前推進一步後，會回傳全新的下一步狀態 s_{t+1}，並根據系統設計的獎勵規則計算出單步的獎勵 r_{t+1}，獎勵將依據偏離車道、違規等現象進行規劃，並將獎勵的值域限制於[0,1]。系統將上述連續發生的數據，包含當前狀態 s_t、執行動作 a_t、獲得獎勵 r_{t+1}、以及下一步狀態 s_{t+1}，以元組的形式完整存入軌跡緩衝區（Rollout Buffer）中。系統會持續錄製這段駕駛軌跡，直到發生碰撞、違規或達到回合最大步數為止，完成訓練回合。

3.1.3 神經網路參數更新機制 (Neural Network Optimization)

當完成訓練回合時，系統會暫停與 CARLA 環境的互動，利用倒傳遞（Backpropagation）演算法來計算梯度並實質微調網路權重。其底層的數學運算邏輯與具體更新過程如下及圖 3 所示。

更新策略前，系統必須先進行廣義優勢估計(Generalized Advantage Estimation, GAE)與動態信用分配（Credit Assignment），以客觀評估自駕車執行的每一個動作的絕對價值。首先，系統計算單步駕駛表現與預期分數落差的時序差分誤差（TD Error）δ_t，

$$\delta_t = r_{t+1} + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) \tag{3.2}$$

將當前動作獲得的即時環境獎勵r_{t+1}，加上價值網路預估的下一步狀態價值$V_\phi(s_{t+1})$，經折扣因子 γ 衰減，再減去原本預估的當前狀態價值$V_\phi(s_t)$，計算出序差分誤差δ_t。假若算出的誤差數值δ_t大於零，表示該轉向或油門操作所帶來的回饋，超出價值網路對當前狀態的預期，

因而產生正向的學習訊號。。為解決自動駕駛長遠軌跡的信用分配問題，系統接著透過廣義優勢估計(GAE)演算法將多步的誤差進行加權整合，

$$\hat{A}_t = \delta_t + (\gamma\lambda)\delta_{t+1} + (\gamma\lambda)^2\delta_{t+2} + \cdots \tag{3.3}$$

將未來的獎懲依據時間衰減合理分攤給過去的控制動作，最終輸出的優勢值 $\hat{A}_t$ 即為直接更新依據。$\hat{A}_t$為正值則提高該動作機率，為負值則降低。系統亦會將計算出的優勢值與原本的預估價值相加，取得目標總回報：

$$R_t = \hat{A}_t + V_\phi(s_t) \tag{3.4}$$

藉此反推出價值網絡在後續計算均方誤差時所需的真實總分目標值。

在確立優勢值與目標總回報後，進入 PPO 多目標聯合損失函數構建（Total Loss Function Construction）階段。考量底層優化器預設執行梯度下降，優化器需透過最小化一個整合型的總損失函數來同步微調決策與評分網路，

$$L_{total}(\theta,\phi) = -L^{CLIP}(\theta) + c_1 L^{VF}(\phi) - c_2 H(\pi_\theta) \tag{3.5}$$

該聯合損失函數由三個子目標組成：方程式(3.5)第一項是用於更新 Actor 網路的策略裁剪代理損失函數（Actor Loss），

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t\left[\min\left(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right] \tag{3.6}$$

其中，新舊策略機率比值$r_t(\theta)$的數學定義為

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)} \tag{3.7}$$

代表當前更新中的新網路（π_θ）給出該動作的機率，與舊網路（$\pi_{\theta_{old}}$）給出相同動作機率的相對倍數。在底層程式運算實作上，為避免直接相除造成數值溢位與不穩定，系統是透過將新舊對數機率（log probability）相減後，再取自然指數來求得此比值，即ratio = exp(log_prob − old_log_prob)。計算出比值後，透過 clip 函數將新舊策略機率比值 $r_t(\theta)$ 強制限制在 $[1-\epsilon, 1+\epsilon]$的安全區間內，本系統設定 $\epsilon = 0.2$。當權重更新幅度過大時直接截斷梯度，防止自駕車策略在訓練中因單次極端值發生突變與毀滅性崩潰。

方程式(3.5)第二項是 Critic 網路自我檢討的價值函數均方誤差損失（Critic Loss），公式為

$$L^{VF}(\phi) = \hat{\mathbb{E}}_t\left[\left(V_\phi(s_t) - R_t\right)^2\right] \tag{3.8}$$

藉由計算預測分數與真實目標總分之間的均方誤差（MSE），強迫 Critic 網路大幅更新權重參數，使其未來預估越算越精準。

方程式(3.5)第三項是做為正向激勵項加入總損失函數的策略熵補償正規化損失（Entropy Bonus），

$$H(\pi_\theta) = \hat{\mathbb{E}}_t[-\log \pi_\theta(a_t|s_t)] \tag{3.9}$$

透過鼓勵較高的熵值來保持動作概率分佈的隨機性，防止模型過早收斂至次佳解，確保自駕車在訓練初期保有足夠的好奇心去主動探索不同的駕駛軌跡。

計算出總損失後，系統進行梯度運算與機率密度調整（Gradient Calculation & Probability Density Adjustment）。優化器會針對目標函數 $J(\theta)$執行偏微分計算引入了對數導數技巧（Log-Derivative Trick）。系統會先對常態分佈的機率密度函數取自然對數（log），將原先複雜的指數與根號運算拆解並抵消為平滑的代數項，隨後再對其求取梯度，進而改變動作常態分佈的物理特徵。

目標函數 $J(\theta)$，即 Actor 損失部分，結合優勢函數$\hat{A}$，可以描述為

$$J(\theta) = r_t(\theta) \cdot A_t = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)} \cdot \hat{A}_t \tag{3.10}$$

將策略函數使用高斯常態分佈描述，即$a \sim \mathcal{N}(\mu, \sigma^2)$，成為

$$\pi_\theta(a_t|s_t) = \frac{1}{\sigma\sqrt{2\pi}} exp\left(-\frac{(a-\mu)^2}{2\sigma^2}\right) \tag{3.11}$$

取對數後機率分佈描述為

$$\ln \pi_\theta(a_t|s_t) = -\frac{1}{2}\ln(2\pi\sigma^2) - \frac{(a-\mu)^2}{2\sigma^2} \tag{3.12}$$

其相對於均值 μ 的偏微分(梯度)為：

$$\frac{\partial \ln \pi_\theta(a_t|s_t)}{\partial \mu} = \frac{a-\mu}{\sigma^2} \tag{3.13}$$

將方程式(3.13)的策略梯度結果代回方程式(3.10)，結合優勢函數 $\hat{A}$ 後，相對於均值 μ 的更新方向為

$$\frac{\partial J(\theta)}{\partial \mu} = r_t(\theta) \cdot \hat{A}_t \cdot \left[\frac{a_t - \mu}{\sigma^2}\right] \tag{3.14}$$

當優勢值大於零時，此梯度會修改神經網路權重，讓下一次遇到相同狀態時，輸出的動作中心 μ 往該次抽樣的高分真實動作 a_t 靠近。

相對標準差 σ的梯度，同樣從對數機率密度函數開始：

$$\ln \pi_\theta (a_t|s_t) = -\frac{1}{2}\ln(2\pi) - \ln \sigma - \frac{(a_t-\mu)^2}{2\sigma^2} \tag{3.15}$$

將其對標準差 σ 求偏微分：

$$\frac{\partial \ln \pi_\theta (a_t|s_t)}{\partial \sigma} = -\frac{1}{\sigma} + \frac{(a_t-\mu)^2}{\sigma^3} = \frac{(a_t-\mu)^2-\sigma^2}{\sigma^3} \tag{3.16}$$

在策略梯度中，結合優勢函數 $\hat{A}_t$ 後，相對於標準差 σ 的梯度調整方向為：

$$\frac{\partial J(\theta)}{\partial \sigma} = r_t(\theta) \cdot \hat{A}_t \cdot \left[\frac{(a_t-\mu)^2-\sigma^2}{\sigma^3}\right] \tag{3.17}$$

此結果賦予系統動態自信心，並影響動作輸出機率分佈的尺度，使其在下一輪訓練中呈現較尖銳的分佈，以縮小探索範圍；或呈現較平緩的分佈，以主動擴大探索範圍。

計算各層節點的梯度後，系統隨即展開反向傳播與網路參數微調（Backpropagation & Weight Update）。

為確立策略優化為主要任務，系統將 Critic 損失權重 $c1$ 設為 0.5，並將熵正則化權重$c2$設為 0.01，以控制價值估計與探索行為對整體更新的影響。由於 Actor 與 Critic 共用特徵抽取器，策略損失、價值損失及熵正則化項所產生的梯度會分別經由兩個分支反向傳播，並在共享特徵抽取器處共同累積；最佳化器再依據加權總損失所計算出的梯度，同步更新共享特徵抽取器的參數；而兩個決策分支的專屬參數則分別根據各自的損失函數進行更新。

隨後，Adam 優化器會依序執行舊梯度清除、反向傳播、梯度裁剪與參數更新，完成網路權重的實質調整。最後進行緩衝區清空與迭代更迭（Buffer Reset）。由於 PPO 屬於 On-policy 演算法，參數更新完成後，軌跡緩衝區中由舊策略收集的經驗資料即不再適用，必須予以清空。自駕車隨即以更新後的神經網路重新進入環境，開啟下一輪的駕駛訓練閉環。

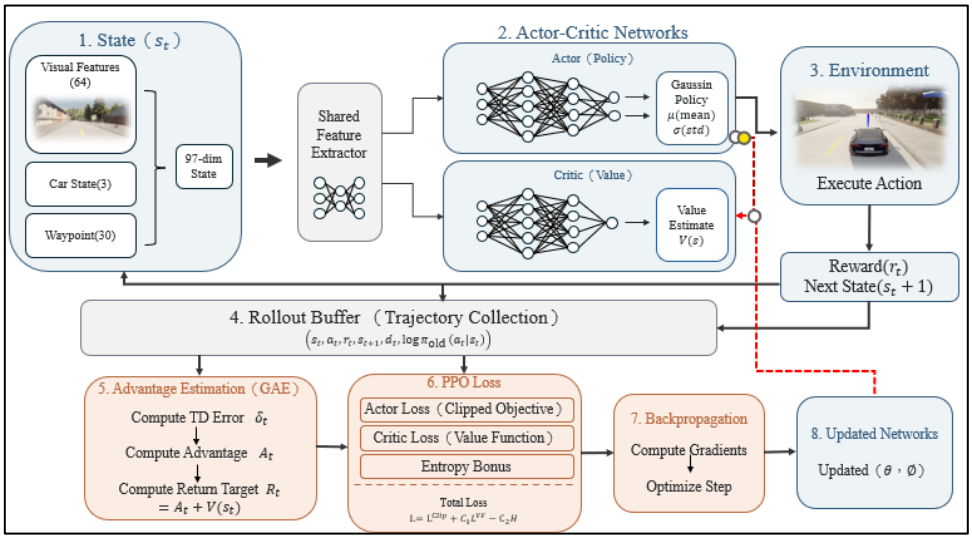


圖 3 參數更新機制

3.1.4 基礎獎勵設計 (Base Reward Design)

系統的核心基礎獎勵是由四個空間與速度因子相乘而得，為避免因為單一因素（如稍微偏離車道）導致乘法後的總分直接歸零而失去學習訊號，空間因子的下限皆被縮放至 0.5，基礎公式為：

$$\text{Reward} = \text{Speed_Reward} \times \text{Cetering}_{\text{Factor}} \times \text{Angle}_{\text{factor}} \times Distance_{Std_{Factor}} \tag{3.18}$$

首先是引導車輛維持在適當巡航速度的速度因子（Speed Reward），在低速爬升區 $V \leq V_{min}(25)$ 時公式為

$$\text{Speed_Reward} = \frac{V}{V_{min}} \tag{3.19}$$

最佳巡航區 $V_{min}(25) < V \leq V_{target}(40)$ 時

$$\text{Speed_Reward} = 1.0 \tag{3.20}$$

而超速懲罰區 $V > V_{target}(40)$ 時則為

$$\text{Speed_Reward} = 1.0 - \frac{V - V_{target}}{V_{max}(50) - V_{target}} \tag{3.21}$$

其次是車道居中因子（Centering Factor），根據車輛偏離車道中心的距離 D 進行扣分，完美置中時數值為 1.0，D_{max} 為容許最大偏離距離（設為 3.0 m），公式為

$$\text{Centering_Factor} = \max\left(1.0 - \frac{D}{D_{max}}, 0.0\right) \tag{3.22}$$

接著是評估車身方向與道路切線方向夾角 θ 的車身角度因子（Angle Factor），車子完全平行標線時給予最佳獎勵，藉此避免車輛在車道內橫衝直撞（最大偏離角度 θ_{max} 設為 90°），公式為

$$\text{Angle_Factor} = \max\left(1.0 - \left|\frac{\theta}{\theta_{max}}\right|, 0.0\right) \tag{3.23}$$

最後是計算過去 30 步車道偏移量標準差 σ 的歷史穩定度因子（Distance Std Factor），行駛越穩定、標準差越低，得分越接近 1.0，反之則懲罰在車道內蛇行的行為（最大標準差 σ_{max} 設為 0.4），公式為

$$\text{Distance_Std_Factor} = \max\left(1.0 - \frac{\sigma}{\sigma_{max}}, 0.0\right) \tag{3.24}$$

另外，定義了終止條件為車輛在駕駛過程中發生碰撞、偏離車道、超速或闖紅燈等情況。當車輛與道路以外的物體發生碰撞時，系統立即判定為碰撞違規並終止當前訓練回合；當車輛與車道中心線的距離超過允許上限 D_{max} 時，判定為偏離車道；當車速超過設定的最高速度 V_{max} 時，判定為超速。此外，若車輛在紅燈狀態下通過停止線，且通過時車速高於 $2\ km/h$，則判定為闖紅燈違規。當發生任一終止條件時，給予終止懲罰；若車輛成功完成指定路線，代表該回合成功結束。

3.2 剎車機制設計

本研究在文獻 [8] 所建立的 CARLA-SB3 強化學習環境上，進一步加入煞車控制，使智能體能同時學習方向、加速與減速操作。煞車機制包含三維連續動作設計，以及油門與煞車的互斥控制。

3.2.1 剎車動作設計

文獻 [8] 的原始連續動作空間由轉向與油門組成：

$$a_t = [steer, throttle]$$

其中，$steer$表示轉向輸入，範圍為$[-1,1]$；$throttle$表示油門輸入，範圍為$[0,1]$。

為使智能體能夠學習主動減速與停車，本研究將連續動作空間擴充為三維：

$$a_t = [steer, throttle, brake]$$

其中：

$$steer \in [-1,1]$$

$$throttle \in [0,1]$$

$$brake \in [0,1]$$

三個動作輸出會分別對應至 CARLA 車輛控制介面的 steer、throttle 與 brake 參數。透過加入獨立的煞車維度，智能體不必只能透過減少油門來降低車速，而是能夠根據交通號誌、前方路況及車輛速度主動產生煞車行為。

3.2.2 油門與剎車互斥設計

為避免智能體同時踩下油門與煞車，本研究加入油門與煞車互斥機制。當油門輸出大於煞車輸出時，只保留油門；反之，則只保留煞車：

$$(throttle, brake) = \begin{cases} (throttle, 0), throttle > brake \\ (0, brake), brake \geq throttle \end{cases} \quad (3.25)$$

3.3 紅燈偵測與動作設計

3.3.1 紅燈偵測

本研究讀取模擬器的號誌狀態，加入紅燈觸發與違規判定機制，供智能體學習減速與停車。系統會記錄車輛是否處於紅燈觸發區，當車輛前一時刻位於紅燈區域、下一時刻離開該區域，且交通號誌仍為紅燈、車速高於$2km/h$車輛已通過停止線並構成闖紅燈違規。發生違規時，系統會立即終止當前訓練回合。

為增加紅燈煞車情境的訓練樣本，系統在訓練模式下以 30% 的機率將車輛遇到的交通號誌強制設定為紅燈，並將紅燈持續時間隨機設定為 4–8 秒。系統同時記錄已處理過的交通號誌，使同一路口在同一回合中僅會被強制轉換一次，避免重複觸發紅燈而造成訓練情境失真，或使智能體形成長時間停車的保守策略。

3.3.2 紅燈情況下獎勵機制設計

一般情況下，獎勵函數會鼓勵車輛維持適當速度並沿著車道行駛。然而，若在紅燈時仍以較高速度前進，可能導致 Agent 闖紅燈。因此，系統在偵測到紅燈後，會改變速度獎勵的

計算方式，改為鼓勵車輛減速或停車。

系統會根據車輛與交通號誌的距離D_t，計算紅燈情境下的目標速度

$$V_{stop} = \max(0.0, D_t - 5.0) \tag{3.26}$$

若成功減速或煞停 $V \leq V_{stop} + 2.0$，當車輛乖乖停下或依照距離正確減速時，直接給予滿分速度獎勵 Speed_Reward = 1.0；若煞車不及或硬闖 $(V > V_{stop} + 2.0)$，即車速未降下時則強烈減少獎勵

$$\text{Speed_Reward} = \max\left(0.0, 1.0 - \frac{V - V_{stop}}{10.0}\right) \tag{3.27}$$

除了速度之外，獎勵函數也會考慮車輛是否保持在車道中央、行駛方向是否正確，以及車道偏移是否穩定。若車輛在非紅燈狀態下長時間停滯，系統會給予怠速懲罰；若車輛大幅偏離車道，也會額外扣分。當車輛闖紅燈時，系統會立即終止訓練回合，並給予較大的負向獎勵，以降低智能體再次採取闖紅燈行為的機率。透過上述設計，Agent 能夠學習在紅燈前減速或停車，並在綠燈後恢復正常行駛。

3.4 問題分析

在開發基於強化學習的自駕車決策系統時，我們面臨了傳統控制方法難以克服的環境複雜性，以及神經網路在訓練過程中的收斂瓶頸，主要可歸納為以下兩大挑戰：

複雜動態路況下的決策適應性與泛化難題：真實世界的道路環境充滿了高度的不確定性，傳統基於規則的自動駕駛系統通常只能應對預先定義好的簡單情境。當面對隨機的氣候變化、不同的光照條件或未知的道路幾何形狀時，傳統系統極易產生決策失誤。因此，如何打造一個能夠在 CARLA 高度擬真環境中主動探索、從試錯中學習，並將經驗泛化至各種未知複雜交通場景的學習型決策大腦，是本專案首要解決的問題。

多目標駕駛任務的獎勵衝突與模型收斂困難：在強化學習的訓練過程中，自駕車必須同時滿足多項相互衝突的目標。例如：系統既需要「保持適當車速前進」以提高通行效率，又必須「維持車道置中」避免偏離，同時還得具備「紅燈煞停」的停車控制能力。如果獎勵函數設計不當，PPO 模型很容易陷入次優解，例如過度迴避風險而導致車輛永遠停在原地不走，或是為了追求速度而頻繁衝出車道。如何設計出能兼顧這些多維度目標、引導模型穩定收斂

的複合型獎勵機制，是開發過程中最大的技術挑戰。

3.5 實作結果

本研究將 Stable-Baselines3 的 PPO 演算法用於自駕控制，輸出連續型動作訊號，並搭配方向盤平滑處理，改善控制過程中的車體震盪。從圖 4 、圖 5 的測試數據表，可觀察訓練後車速與車道保持的表現。該次紀錄中，車輛的平均車速為 22.85 km/h，最高車速達 34.65 km/h，已有持續向前行駛的結果；該次紀錄顯示 100% 的任務成功率，以及 681.53 公尺的總行駛距離。報告未明列重複測試樣本數，故此成功率僅描述該次設定。模型使用車道居中與方向穩定獎勵，該次平均車道偏移量（Avg Center Dev）為 0.07 公尺，平均每步獎勵為 0.8959。從對應的鳥瞰軌跡圖（Top-Down View）可看到，代表車輛行駛軌跡的藍線在面臨長直線與 90 度直角彎道時，較能保持車道並減少蛇行。目前結果同時受到獎勵設定與控制後處理影響，仍需對照實驗，才能區分各項修改的效果及換場景後的表現。

我們以複合型獎勵函數兼顧通行與停車，並以圖 7 訓練數據與圖 8 的模擬環境紅燈停車畫面，呈現此設定下號誌資訊與控制流程的執行結果。當自駕車面臨路口紅燈，且前方藍色導航路徑（Waypoints）指示準備右轉時，系統依 CARLA 直接提供的號誌狀態執行停等邏輯，尚未驗證攝影機號誌辨識。畫面左側的遙測儀表板（HUD）數據顯示，此時車速降至 0 km/h；經油煞互斥與控制過濾後，車輛的油門（Throttle）與方向盤（Steer）輸出訊號已完全歸零，而煞車控制參數（Brake）則呈現煞車作動，畫面中的車輛停在停止線前。這說明目前的策略輸出與環境控制可在此情境下完成停車，並由 CARLA 物理引擎執行控制訊號。停車表現包含策略、獎勵與外部控制的共同作用，不能全歸因於 PPO。不同路口、燈色誤判及交通條件下的穩定性仍待測試。

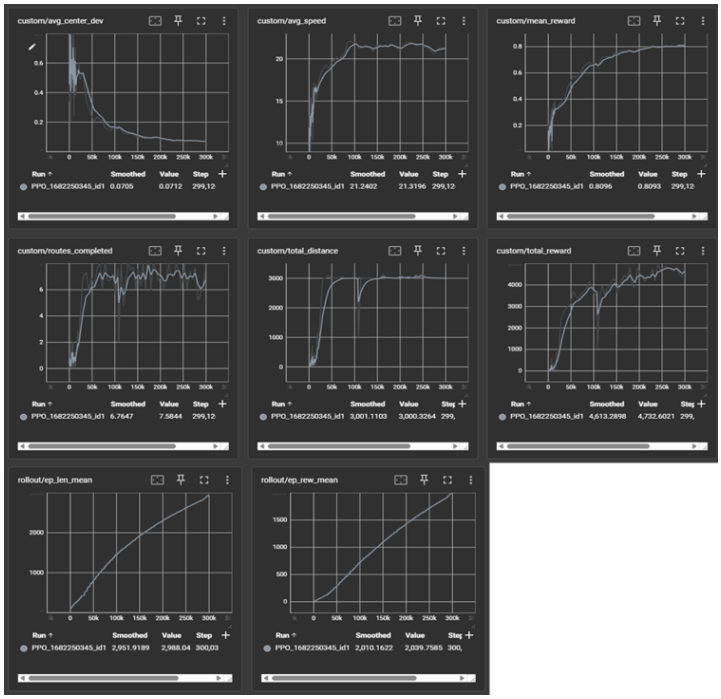


圖 4 強化學習訓練結果

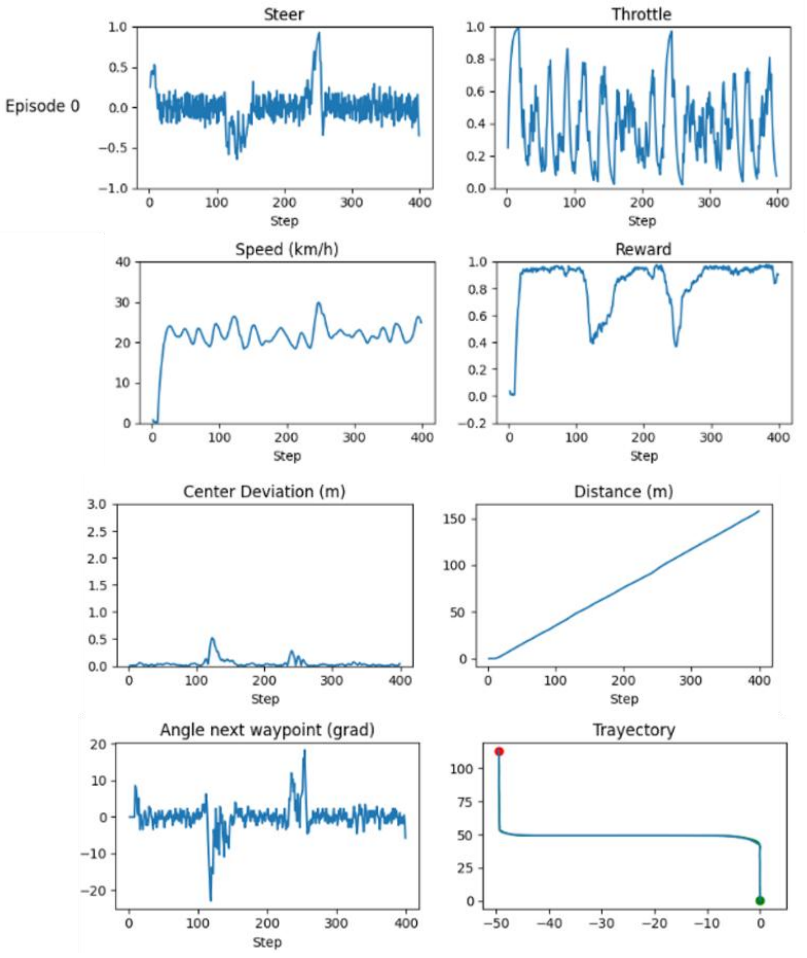


圖 5 強化學習訓練數據

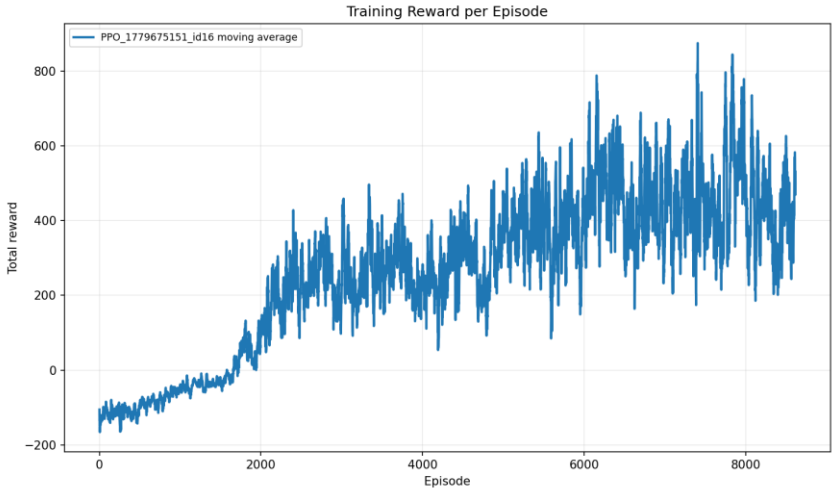


圖 6 訓練每前 20 回合平均獎勵

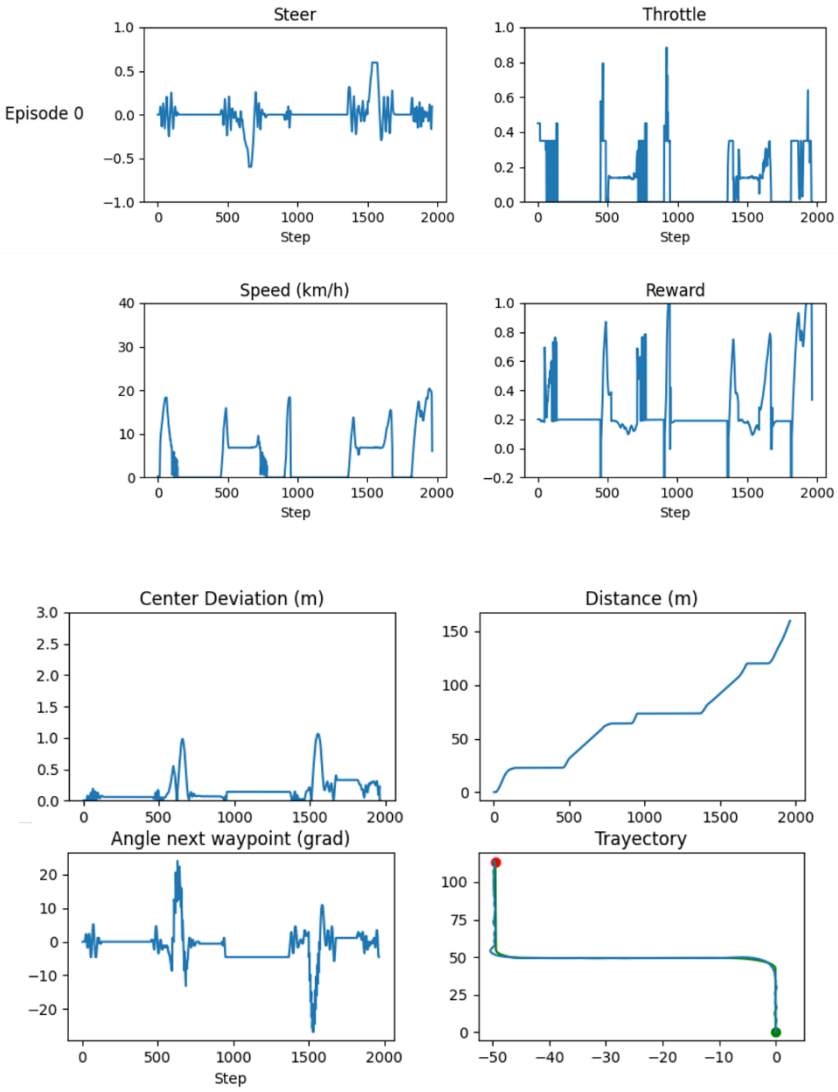


圖 7 強化學習 + 紅燈剎車訓練數據

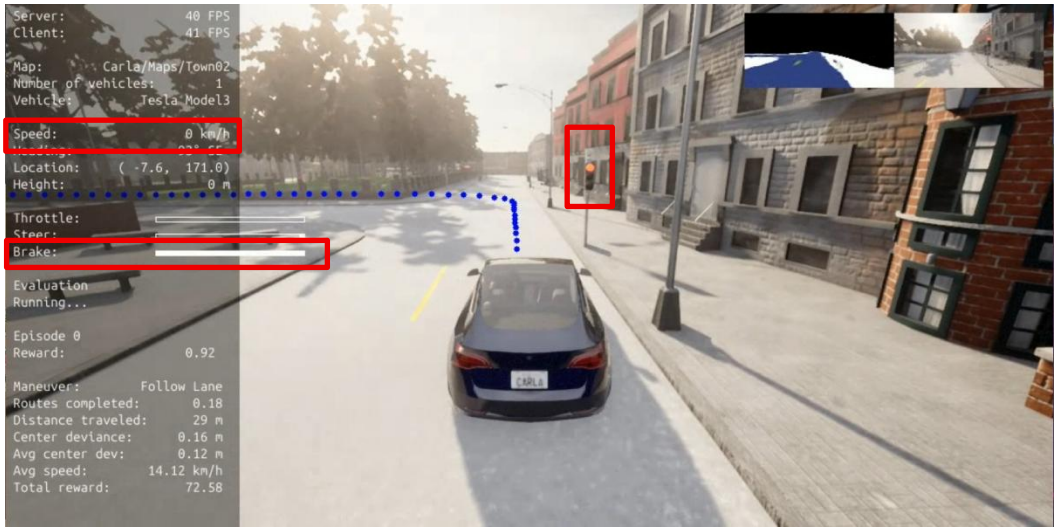


圖 8 訓練結果證明紅燈煞車系統有效

3.6 軟硬體設備

軟體：

- CARLA Simulator：0.9.16
- Pytorch：13.2
- CUDA：13.0
- Stable-Baselines3：2.9.0

硬體：

- CPU：AMD Ryzen 9 7900X3D 12-Core Processor
- GPU：NVIDIA GeForce RTX 4090 × 2
- GPU 記憶體：24 GB／張
- 系統記憶體：128 GB

肆、 VAE 視覺影像資訊獲取與壓縮

在自駕車系統之中，道路提供之資訊為重中之重，道路之標線、號誌、路上之行人與車輛是車輛駕駛中的規則，在本專案中使用及使用過以下技術作為提取道路資訊之工具。

4.1. 傳統影像處理-邊緣檢測與霍夫變換

Canny 邊緣檢測是傳統之影像處理辦法，先透過高斯矩陣過濾雜訊，比起深度學習，傳統影像處理方法更依賴數學幾何與特徵提取，優點是運算量小、不需標記資料，但是對光影的變化尤為敏感，除此之外也無法確認辨識出來之邊緣是否為必要之資訊（如道路標線、前方車輛等）。霍夫直線是將經過邊緣檢測後的特徵點輸入極座標（Polar Coordinates），在此參數空間原始圖像上的一點會變化為一條正弦曲線，而同一條直線上的點會在極座標中有一個交點，並以此作為是否為同一條直線之依據。



圖 9 邊緣檢測與原始圖片對比

4.2. LaneNet 道路線分割模型

LaneNet 是專門為車道分割設計的模型，和物件分割的模型相似，首先透過預訓練模型（如 VGG16, Enet）作為提取輸入照片之特徵，再經由兩條不同的路線，其一為二元分割之分支，主要利用編碼後之特徵進行二元重建，分辨道路線與背景，其二為語意分割分支，透過將車道線像素進行**嵌入向量（Embedding Vectors）**，透過餘弦相似性進行比對，相同之道路線其相量距離會十分相近，再透過 **DBSCAN** 等聚類演算法，將向量進行分群，每一群代表獨立的車道線。

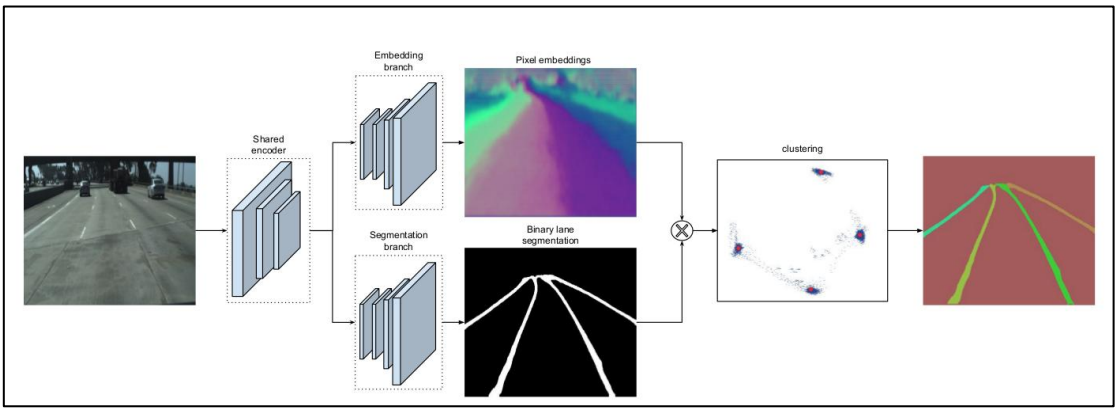


圖 10 LaneNet 網路架構

4.3. VAE（Variational Autoencoder，變分自編碼器）

Encoder（編碼器） 將輸入影像透過卷積層進行降維和提取特徵，因為原始影像包含了許多駕駛車輛不需要的資訊，譬如路邊的商家賣什麼東西，透過壓縮的同時將不必要的資訊進行剔除，最終將原始影像壓縮為 64 維之向量，與其他自駕車輛之特徵（如車速、油門、煞車等動作）混合輸入強化學習之中，作為強化學習之特徵來源。

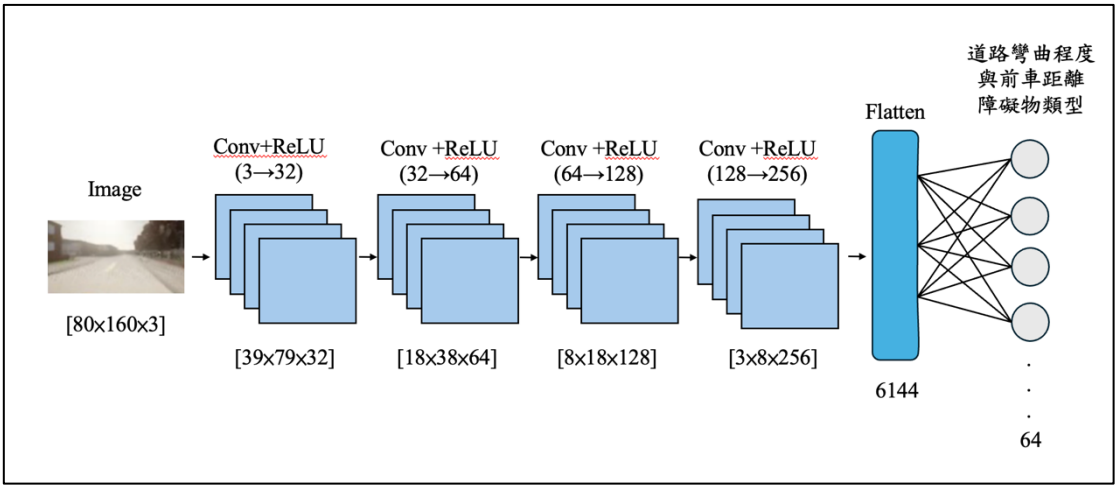


圖 11 Encoder 架構

Decoder（解碼器）主要功能是將編碼器壓縮之 64 維利用反卷積進行重建，以**自我監督（Self-supervised Learning）**之形式進行訓練，透過編碼器重建影像，確認編碼器壓縮之特徵是否重要，重建時的圖像清晰度與道路的辨識度，以此來確認編碼器訓練之成果。

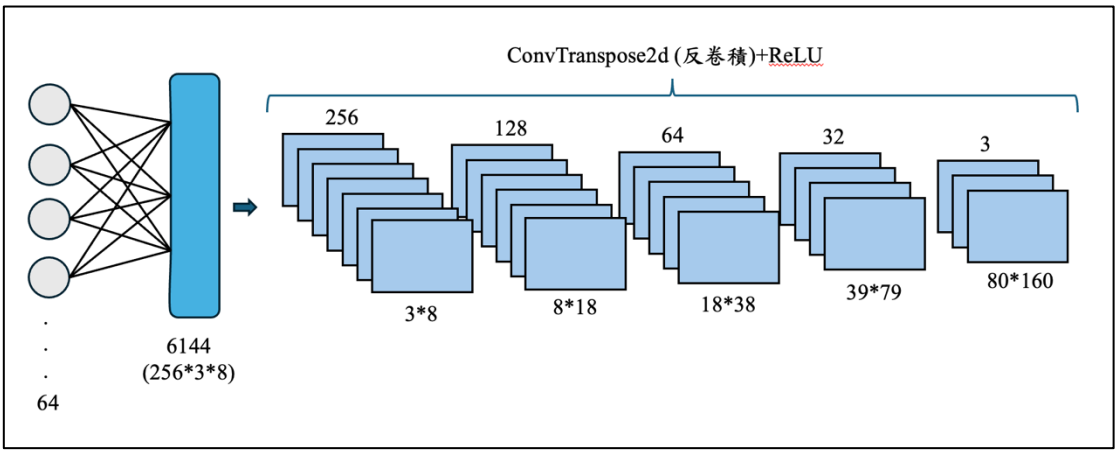


圖 12 Decoder 架構

4.4. 問題分析

作為強化學習的道路資訊來源，透過編碼器的架構壓縮影像資訊，但在實際應用於自駕車決策時，VAE 主要面臨以下三大問題：

VAE 的特性容易讓重建的畫面變得模糊。在自駕場景中，遠處的小紅綠燈、前方車輛的煞車燈或地上的車道線，往往只佔影像中的幾個像素。VAE 在壓縮時很容易把面積小但重要的資訊當成雜訊抹掉，導致 PPO 模型推論時缺少重要資訊。

自駕環境中的天氣變化極大（晴天、暴雨、濃霧、夜間）。對 VAE 來說，同一條馬路在晴天和暴雨下的像素表現完全不同。這會導致編碼器（Encoder）將不同天氣壓縮出來的隱向量，在隱空間中散落在完全不同的區域。當天氣動態切換時，隱空間的特徵大幅跳動，後續的決策大腦就會因為接收到不穩定的訊號而無法適應。

當車輛行駛到 VAE 從未看過的全新場景（例如特殊的道路幾何、沒見過的障礙物或極端天災畫面）時，編碼器無法正確處理這些未知像素，只能強行將其對齊到最接近的已知特徵上。這種面對未知事物時的泛化無能，會導致解碼器重建出扭曲變形的畫面（無法正確還原現實），或是輸出毫無意義的錯誤隱向量，使系統徹底失去對周遭環境的正確感知。

4.5. 實作結果

LaneNet 利用共享編碼器作為基底提取道路特徵，並透過雙分支網路同時進行二元分割與像素嵌入。最終透過特徵截取和 DBScan 分群演算法，將車道線進行非線性聚類與實例分

割，有效在複雜或多車道場景下精準區分每條獨立車道，大幅提升車道維持能力。

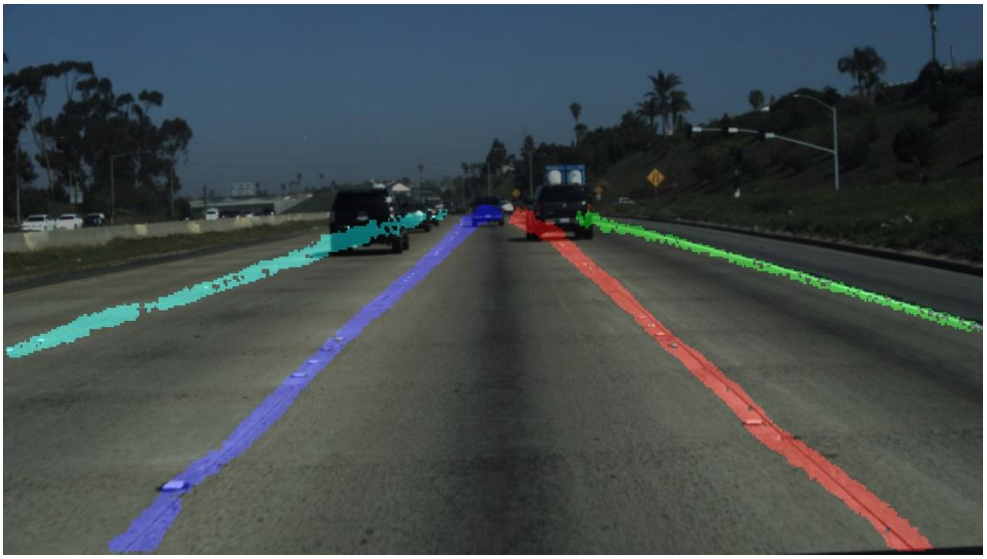


圖 13 LaneNet 模型輸出

引入變分自編碼器（Variational Autoencoder, VAE）對 120*80 的前視相機影像進行降維與潛在空間（Latent Space）表徵提取。在保留關鍵道路幾何與障礙物特徵的前提下，將影像資訊極致壓縮為 64 維向量，顯著降低遠端傳輸頻寬與後端控制模型的計算負載。



圖 14 前視相機影像

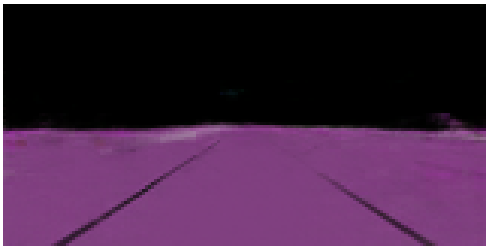


圖 15 VAE 模型輸出影像

伍、 DVS 事件相機與自動緊急煞車系統（AEB）

AEB 系統完全基於純視覺感知（Vision-based AEB），僅透過 YOLO Bounding Box 的幾何計算完成從感知到煞車的完整閉環。

5.1. 視覺感測與技術探索

傳統 RGB 相機以固定幀率（如 30 fps）輸出全局靜態影像，這在高速行駛或光線劇烈變化的場景中容易產生動態模糊與過曝。事件相機（DVS, Dynamic Vision Sensor）模仿生物矽視網膜機制，採「非同步」運作：只有當像素點的亮度變化超越特定閾值時，才會觸發並輸出帶有微秒級時間戳、座標與極性（亮度增減）的「事件（Event）」。其優勢在於極高的時間解析度、高動態範圍（HDR）與極低功耗，且因僅捕捉「動態邊緣」，能天然去除無用的靜態背景，非常適合用於突發的防碰撞預警場景。

本系統嘗試以各式工具將 RGB 相機錄製後影像進行模擬轉換，包含 V2E 工具轉換與 DVS 轉換算法。為處理 DVS 非同步事件流，初期研究了 SNN 架構。SNN 以脈衝（Spike, 0/1）傳遞訊號，神經元累積膜電位（Membrane Potential）超過閾值才發放脈衝，符合 DVS 的時間離散特性。實作上採用「混合持續學習（Continuous Learning）」機制，以「學習→預測→修正」循環懲罰短期過擬合特徵、強化長期動態規律。

SNN 訓練指標顯示：手寫數字無監督分類可達高準確率；車輛移動偵測（靜止/移動二分類）前 100 步 F1＝0（模型未學習），100 步後靜止類別 F1 趨近 1.0，資料標籤均衡。然而後期訓練損失曲線出現劇烈震盪，Gradient Norm 突降，深層網路收斂困難，此為轉換架構的直接原因。

SpikeYOLO [5] 是基於 YOLOv8 進行神經形態改造（參照圖 16），Macro Design 保留 Backbone－Neck－Head 多尺度特徵融合結構，Micro Design 引入 Meta SNN Block（Token Mixer 採 SepConv 倒殘差結構提取空間特徵；Channel Mixer 處理通道間資訊融合），Spike-driven Core 以 I-LIF（Integrate-and-Fire）脈衝神經元取代 ReLU/SiLU。訓練期以整數值近似穩定反向傳播，推論期完全依賴二值脈衝，達到「無事件即無運算」的極致節能目標。初步以 N-Caltech101 DVS 資料集（將 ATIS 感測器安裝於電動平移傾斜單元，在 LCD 螢幕前移動

錄製 Caltech101 類別影像所得）進行訓練，取得初步偵測成果（經測試摩托車類別置信度可達 90.5%）。

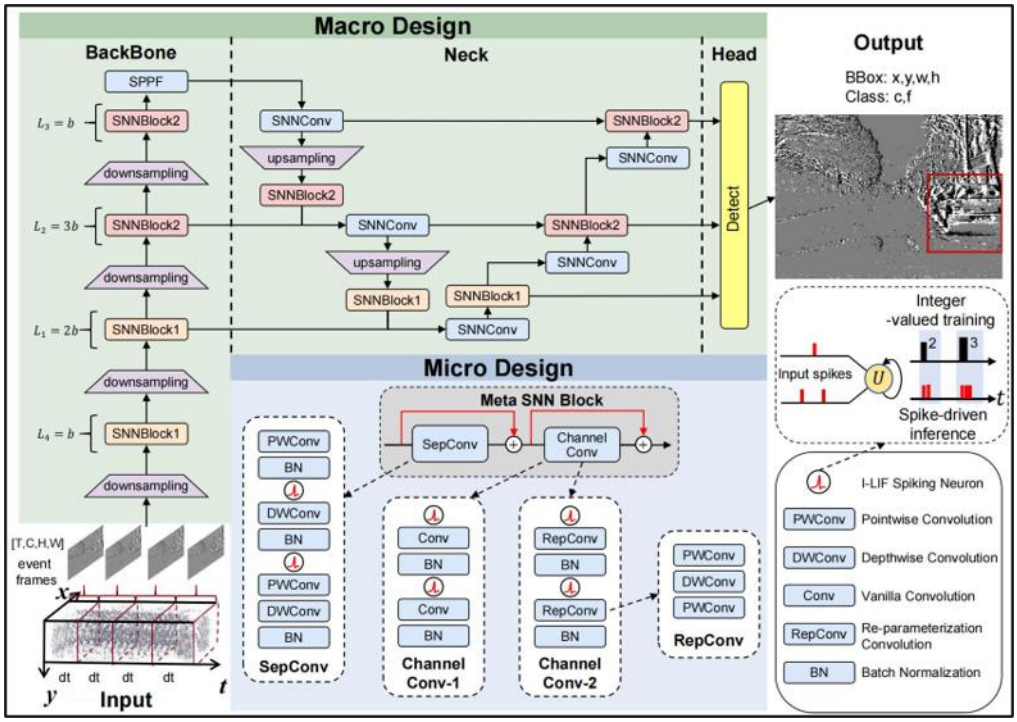


圖 16 SpikeYolo 架構

儘管 SNN 與 SpikeYOLO 在理論功耗上極具潛力，但在實務推進中遇到了瓶頸：訓練不穩定。從訓練日誌中觀察到後期 Loss 曲線出現劇烈震盪與梯度範數（Gradient Norm）突降的問題，SNN 的不可導特性使得深層網路難以收斂，評估後我們認為無法保證達到生命安全級別的模型可靠度。目前的 SNN 框架缺乏成熟的即時推論優化，難以與 CARLA 模擬器進行 30 fps 以上的即時物理雙向通訊，AEB 系統的反應時間要求無法滿足。轉換後採用 YOLO26（CNN）搭配傳統 RGB 影像，可在毫秒內輸出穩定 Bounding Box，將研究重心轉移至閉環控制邏輯與動態幾何演算法。

視覺數據合成與標註工程初期引入 V2E（Video-to-Events）工具，以 SuperSloMo 進行時間插值填補幀間空隙，再依 Weber-Fechner 定律進行 Lin-Log 轉換模擬人眼對比度感知，最後設定正負閾值（±0.15）並加入散粒噪聲（Shot Noise）生成高擬真非同步事件流。然而 V2E 存在以下固有問題：可能遺漏微弱亮度變化；缺乏感光器雜訊、真實反應曲線與 Dead Time 特性；偽事件（亮度估算不準確所致）；時間解析度受幀率限制（30 fps 影片最多每 33 ms 一段事件）。因 V2E 需經過時間插值補幀，在轉換速度上極為緩慢，我們自行研究輕量級即時轉

換腳本。

空間去噪與光受器對數轉換（Logarithmic Conversion）：將 BGR 影像轉為灰階後施加高斯模糊（核大小 5×5）去除感測器雜訊，再依韋伯-費希納定律取自然對數，建立對比度不變表示。以對數域計算的相對亮度差 ΔL = L_curr − L_ref 等同於兩幀的亮度比例 log(A/B)，正值表示亮度放大，負值表示亮度縮減，對絕對光照不敏感。

時間差分與閾值觸發（Temporal Difference & Thresholding）：計算當前幀與基準幀的對數亮度差，依物理閾值 θ = 0.15 觸發 ON/OFF 事件。

非同步基準重置（Asynchronous Reference Update）：僅針對已觸發事件的像素進行基準幀局部更新，避免靜止背景持續累積誤差。未觸發像素的基準幀保持不變，實現 SNN 積分（Integrate）、發射（Fire）、重置（Reset）的完整邏輯模擬。

輸出畫面中，白色像素（255,255,255）代表正極性 ON 事件，黑色像素（0,0,0）代表負極性 OFF 事件，灰色像素（127,127,127）代表無事件背景，天然去除靜態背景並保護人臉/車牌隱私。轉換後的偽 DVS 畫面保留了「去除靜態背景」與「抹除人臉/車牌隱私」的優勢。初期由於原始 CARLA 錄影僅 8 fps，導致重置時畫面產生嚴重空白閃爍；後續我們擷取幀率提升至 30 fps 以上，確保了亮度變化的連續性，大幅改善了視覺穩定性。

為解決手動標註耗時且誤差大的問題，我們採用 CARLA 的實例分割相機（Instance Segmentation Camera）進行全自動標註。並將相機拍下影像中 RGB 的 R 通道值對應場景物件的類別 ID（Car = 14、Truck = 15、Bus = 16），程式自動掃描像素聚落，提取最外圍極值轉換為精準的 Bounding Box，實現高品質資料集全自動建構。

YOLO26 模型訓練參數：epochs = 100（初步）/ 500（最終調整）、imgsz = 320、batch = 16，資料集共 13,340 張影像，類別為 Car（0）、Truck（1）、Bus（2）。訓練結果（參照圖 17）：定位損失（box loss）、分類損失（cls loss）與分佈焦點損失（dfl loss）曲線均平滑收斂，驗證集曲線與訓練集同步，無過擬合；最終 mAP50 穩定達到 95% 左右，mAP50-95 亦持續提升，

為後即時測距提供極度堅實的感知基礎。

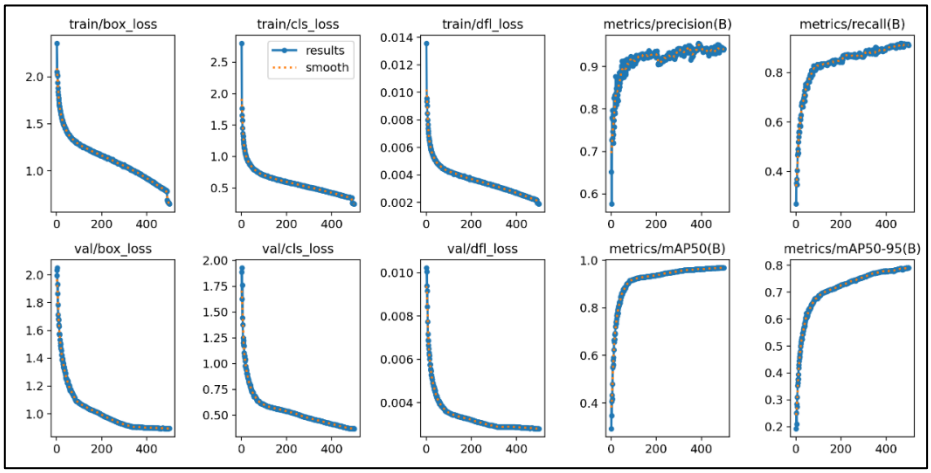


圖 17 Yolo 訓練結果

5.2. 幾何測距與動態控制演算法

在缺乏 LiDAR 深度資訊的情況下，系統利用針孔相機模型（Pinhole Camera Model）與相似三角形原理，將 YOLO 輸出的 2D Bounding Box 逆推回 3D 現實座標 (X, Z)，Z 為縱向深度，X 為橫向偏移。

相機焦距推算（Focal Length Estimation）：利用 CARLA 中設定的已知硬體參數（影像寬度 W_img 與水平視野角 FOV）逆推相機像素焦距 f。本專案設定值：W_img = 960 px、FOV = 90°。相機掛載於車輛前方 x = 1.5 m，高度 z = 1.9 m（CAMERA_TRANSFORM）；BEV 建構時使用 h_cam = 2.4 m。

縱向深度估算（Forward Distance Z）：捨棄因車輛轉向或斜側觀測會劇烈變形的車寬，改採「車輛實體高度 H_real」作為幾何基準，結合 YOLO 偵測框像素高度 H_pixel 推算前方絕對距離 Z。各類別物理高度設定（REAL_HEIGHTS）：假設現實平均車輛高度：轎車 1.5m、卡車 3.0m、公車 3.2m。

選用車輛高度的原因：在絕大多數平路行駛情境下，無論觀測角度（車輛直行、轉彎、側方）如何變化，車輛的實體高度保持恆定，大幅提升測距穩定性。相對地，車輛像素寬度會因前車轉彎或本車由斜側方觀測而產生非線性劇烈變化，不適合作為測距基準。

橫向位移估算（Lateral Offset X）：利用目標 Bounding Box 中心點像素 cx 與畫面物理中心 cx（= W_img / 2 = 480 px）的偏差，配合已求得的深度 Z，換算為現實橫向公尺數。cx 由

YOLO 偵測框座標計算：cx = (x1 + x2) / 2，單位為像素。X > 0 表示目標偏右，X < 0 表示目標偏左。

5.3. 物件追蹤與速度濾波

IoU 跨幀追蹤：YOLO 單幀推論容易產生 Bounding Box 閃爍（同一車輛在相鄰幀的偵測框位置不穩定），若直接計算帧間距離差求速度，會產生極大雜訊。引入交併比追蹤（IoU Tracking）建立跨幀對應關係，其中 xA = max(x1_A, x1_B)、xB = min(x2_A, x2_B)，以此類推。當 IoU > 0.3（IOU_TRACK_THRESH）時，判定前後幀偵測框為同一實體，建立歷史軌跡並傳遞平滑後的距離與速度。

Bounding Box 平滑（ALPHA_BBOX = 0.4）

分離式 EMA 距離濾波（ALPHA_DIST = 0.2）：對距離使用較高敏感度（α = 0.2）的指數移動平均，保留快速接近的響應性。

相對速度推算與 EMA 速度濾波（ALPHA_SPEED = 0.05）：由平滑距離計算原始相對速度（正值代表目標距離縮短、正在靠近）。異常值濾除：若|V_raw| > 28.0 m/s（約 100.8 km/h），視為雜訊，保留前一幀速度估計，接著以極度平滑的 EMA（α = 0.05）抑制殘餘雜訊。

設計說明：距離（α = 0.2）與速度（α = 0.05）採用不同靈敏度的分離式濾波，使距離追蹤保持對快速靠近車輛的響應性，同時讓速度計算高度平滑以免 TTC 計算受雜訊影響。

橫向速度追蹤（Cut-in Detection）：計算目標偵測框中心點在連續幀之間的橫向位移速度，用於識別切入威脅。

5.4. 行駛走廊過濾與切入偵測

本車路徑劃定畫面橫向中央 50%範圍（PATH_LEFT = 240 px 至 PATH_RIGHT = 720 px，即 W_img × 25%至 W_img × 75%）定義為「本車專屬行駛路徑」。Bounding Box 中心 cx 在此範圍外的車輛視為側方車輛，若為靜止（|smooth_speed| < 0.5 m/s）則標示為「PARKED/Side」並豁免於 TTC 計算，避免路邊停車觸發誤煞。即使車輛當前位於路徑外，若橫向速度超過閾值（LAT_THREAT_SPEED = 2.0 m/s），系統判定其有切入意圖，拔除豁免權並納入威脅評估。

路徑內車輛（240 ≤ cx ≤ 720）與切入威脅車輛均納入 TTC 計算，更新全局最小距離 min_dist 與最小 TTC min_ttc。

5.5. TTC 動態決策與遲滯狀態機（Hysteresis State Machine）

碰撞時間（TTC）計算：將空間資訊轉化為時間維度的風險評估指標。當 V_smooth ≤ 0.1 m/s（目標相對靜止或正在遠離）時，TTC 設為無限大，不觸發緊急煞車。此設計避免了因對向靜止障礙物引發誤判。

維護絕對距離保底機制：min_abs_dist 追蹤所有偵測車輛中最近的距離，不限制在路徑內，當靜止車輛距離過近（< 3.0 m）時仍強制觸發急煞，防止低速追撞。

AEB 遲滯狀態機：為解決 TTC 在臨界值附近浮動所造成的「控制震盪（走走停停）」問題，採用非對稱進入/退出條件的遲滯狀態機（Hysteresis Control）。遲滯設計的關鍵在於進入（TTC < 6 s）與退出（TTC > 8 s）使用不同閾值，形成 2 s 的緩衝帶，確保系統在危機解除後才平穩恢復控制，而非在臨界點反覆切換。AEB 啟動時立即剝奪 RL 控制權，危機解除後恢復使用者原本的自動駕駛狀態。

各參數整理：急煞距離保底 3.0 m、急煞 TTC 3.0 s、緩煞 TTC 6.0 s、解除 TTC 8.0 s、解除距離 4.0 m。

5.6. 數據降維與鳥瞰圖儀表板設計

系統輸出解析度為 1280×720，分為左側 BEV 面板（VIZ_W = 420 px）與右側前視相機面板（CAM_W = 860 px），兩者水平拼接（np.hstack）即時顯示，再將幾何測距模組輸出的物理座標 (local_x = Z, local_y = X) 映射至 BEV 畫布。

為在 BEV 面板背景呈現道路輪廓，實作逆透視投影矩陣（IPM, Inverse Perspective Mapping）。利用針孔相機模型，定義 3D 空間中 4 個已知物理座標錨點，正向投影至影像平面（使用相機高度 h_cam = 2.4 m）取得來源點 (src_pts)，再對應至 BEV 畫布取得目標點 (dst_pts)。

使用 OpenCV cv2.getPerspectiveTransform 求解 3×3 透視矩陣 H，再以 cv2.warpPerspective

將語意分割相機影像（提取道路 ID=7、車道線 ID=24 的像素）轉換為 BEV 視角，疊加為面板背景。

最終 BEV 面板底部設置 HUD 顯示即時車速（km/h）與系統狀態（AUTOPILOT / AEB SOFT BRAKE / AEB HARD BRAKE!），前視相機面板疊加 YOLO Bounding Box（距離標籤）與警示橫幅（Alert Banner）。

5.7. 問題分析

表 1

問題類型	問題描述	解決方案
SNN 訓練不穩定	後期 Loss 曲線劇烈震盪，Gradient Norm 突降，深層網路難以收斂	策略轉換：改採成熟 YOLO26（CNN）保證推論穩定性
閉環控制高延遲	SNN 框架缺乏即時推論優化，無法維持 30 fps 以上雙向通訊	放棄 SNN 路線，改用 CNN 可在毫秒內輸出穩定 Bounding Box
V2E 轉換過慢	Video-to-Events 處理速度遠低於即時需求	自研 DVS 轉換輕量算法，利用 log 差分閾值觸發即時轉換
低幀率閃爍	原始錄影僅 8 fps，兩幀亮度變化不達閾值產生空白閃爍	將擷取幀率提升至 30 fps 以上確保亮度變化連續性
多車並排誤判 TTC	兩車靠近時系統抓錯歷史軌跡，相對速度瞬間爆表	引入 IoU 追蹤（IOU_TRACK_THRESH = 0.3），跨幀匹配同一車輛
路邊車輛誤煞	路邊靜止車輛觸發 3 公尺急煞條件	劃定畫面中央 50%（240～720 px）為本車路徑，側方靜止車豁免
控制震盪	TTC 在臨界點附近反覆進出造成走走停停	設計非對稱遲滯：進入 TTC<6s，退出須 TTC>8s 且距離>4m
切入車未偵測	相鄰車道車輛以高速切入時無法預警	計算橫向像素速度，超過 2.0 m/s 閾值時納入煞車計算
車寬測距不穩	前車轉彎或側方觀測時車寬像素劇烈變化	改採車輛高度作為基準，行駛情境下高度幾何恆定

5.8. 實作結果

DVS 即時轉換：基於 log 差分閾值觸發算法（θ ＝0.15，ε ＝1×10^{-5}），在 30 fps 下穩定運作，成功去除靜態背景並保護隱私（車牌、人臉不可見）。原始 8 fps 閃爍問題於幀率提升後完全解決。

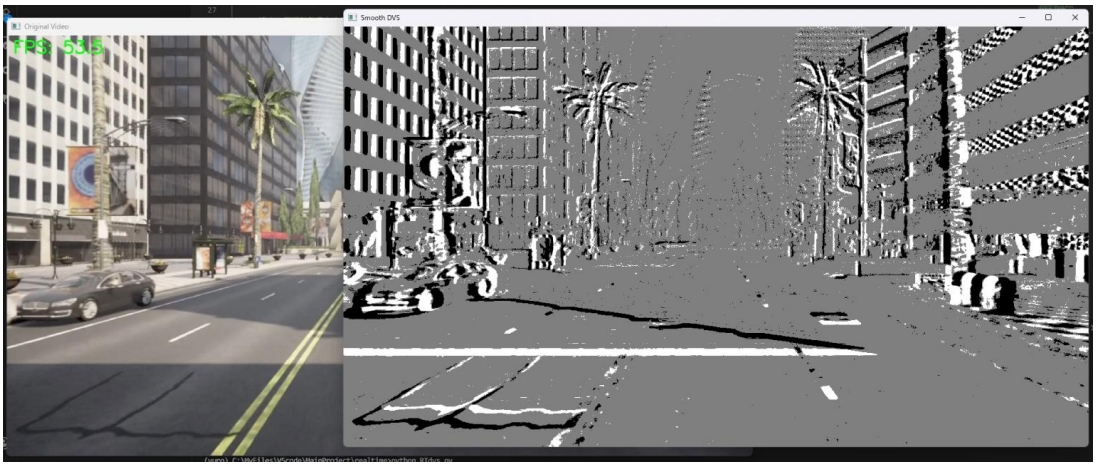


圖 18 修正後影像可即時轉換

YOLO26 訓練成果（最終 500 epochs）：mAP50 穩定達到 95%左右，定位損失（box loss）與分類損失（cls loss）曲線平滑收斂，驗證集與訓練集同步，無過擬合，可直接部署於生產環境。

資料集：利用 CARLA 實例分割相機自動標註，建立 13,340 張涵蓋轎車、卡車、公車三類的高品質影像資料集，大幅縮短人工標註時間。

測距模組：針孔相機模型測距（f = 480 px，各類別真實高度：轎車 1.5 m、卡車 3.0 m、公車 3.2 m），在絕大多數平路情境下測距結果穩定，綠框（>10 m）與紅框（<10 m）視覺回饋清晰。改採車輛高度後，前車轉彎或側方觀測時的測距穩定性大幅提升。

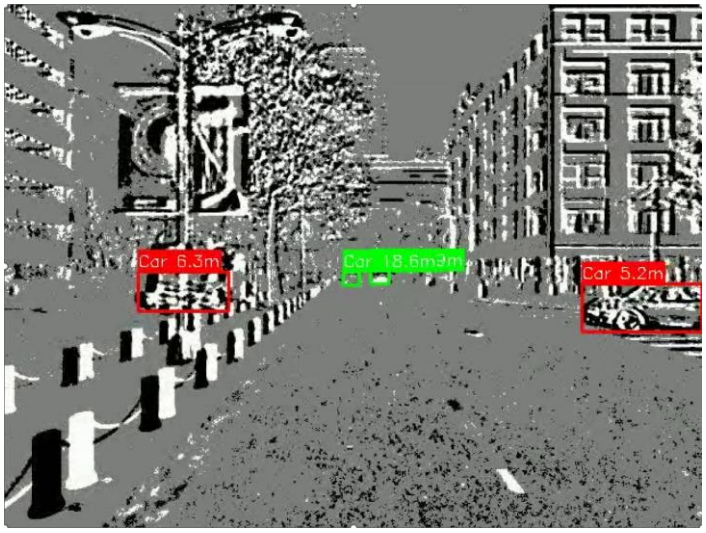


圖 19 綠框:相距十公尺以上、紅框:相距十公尺以內

IoU 追蹤（IOU_TRACK_THRESH = 0.3）：解決多車並排誤判問題，建立跨幀同一車輛的歷史軌跡，TTC 計算不再因車輛位置交換而瞬間爆表。

分離式 EMA 雙濾波（α_dist = 0.2，α_speed = 0.05）：Bounding Box 抖動與速度噪聲大幅降低，TTC 值趨於平穩，避免因雜訊導致煞車反覆切換。異常速度（>28 m/s）自動過濾機制確保系統穩健性。

TTC 遲滯狀態機：進入 AEB State 1（TTC < 6 s，緩煞 0.4）、進入 State 2（TTC < 3 s 或絕對距離< 3 m，急煞 1.0），退出條件（TTC > 8 s 且距離 > 4 m）確保危機解除後平穩恢復，走走停停控制震盪問題完全消除。

行駛走廊過濾（路徑 240～720 px）搭配 Cut-in 偵測（橫向速度閾值 2.0 m/s）：路邊停車誤煞率接近零，切入車輛（從左右車道快速切入者）仍能被即時偵測並觸發預警。

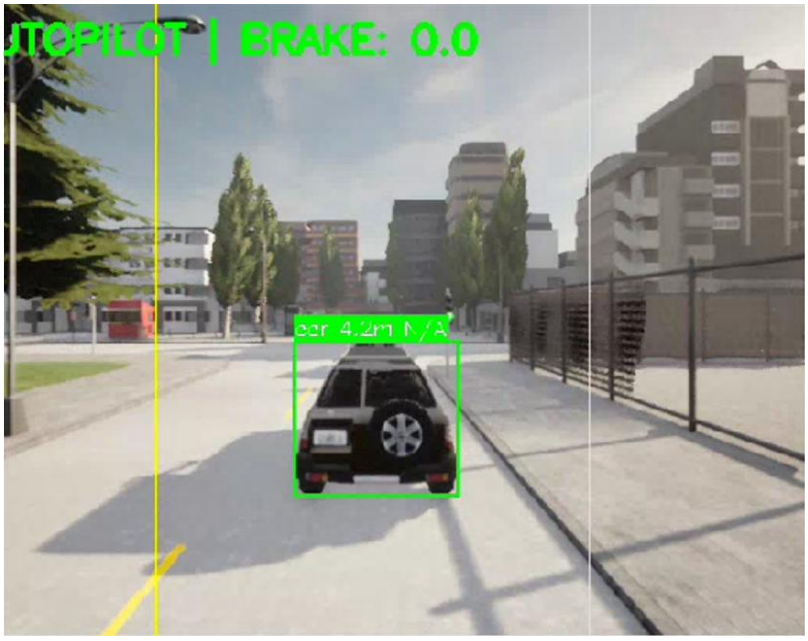


圖 20 黃線與白線為左右邊界外，非高速進入車輛忽略不計

BEV 鳥瞰圖：縱向比例約 9.31 px/m（70 m 範圍），橫向比例 10.5 px/m，自車中心固定顯示，周邊車輛依物理座標精確繪製（安全距離綠色標示、12 m 內橘色警告、8 m 內紅色危險），ALERT_CAUTION = 12 m、ALERT_NEAR = 6 m 動態橫幅提示。語意分割背景（道路 ID=7、車道線 ID=24）經 IPM 矩陣透視轉換後疊加為 BEV 背景，直觀呈現本車所在車道與路寬。HUD 即時顯示車速、系統狀態（AUTOPILOT / AEB SOFT BRAKE / AEB HARD BRAKE!）。

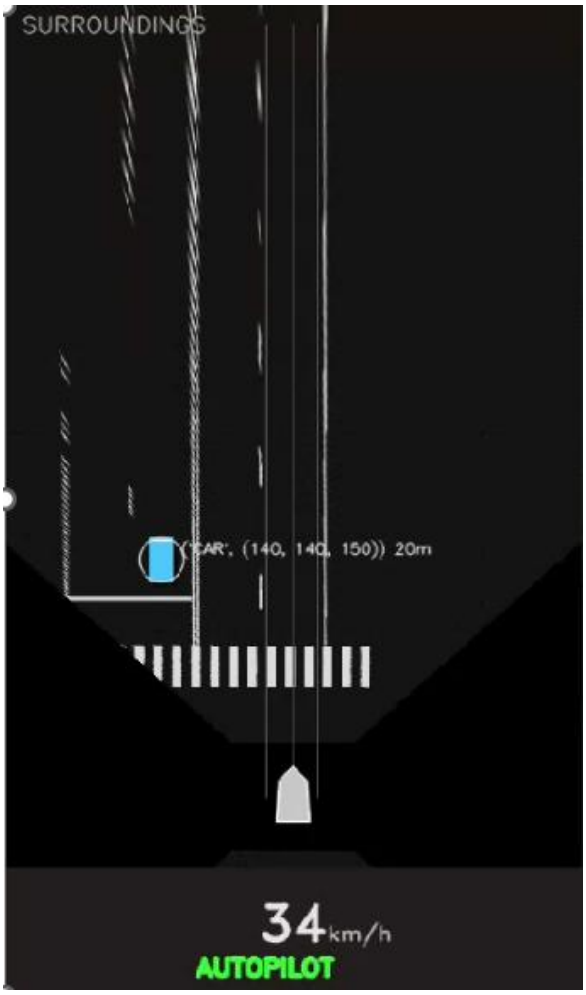


圖 21 鳥瞰圖最終成像

陸、 整合

6.1. 問題分析

在進行系統級整合時，智慧自駕系統涵蓋了複雜的異質技術（如深度學習感知、強化學習決策與狀態機控制），這些模組在獨立開發時往往難以確保即時連動。如何克服各模組間的通訊延遲與資料格式落差，在 CARLA 模擬器中串接出無縫雙向反饋的「感知 → 決策 → 控制」自動化閉環平台，是系統落地前必須解決的工程痛點。

此外，雙控制系統間的權限衝突與平滑切換也是一大難題。在整合主動巡航（RL）與被動防護（AEB）時，車輛等同於擁有兩個決策大腦。若缺乏明確的優先級與介入機制，雙系統極易爭奪煞車與油門的控制權，導致車體動態失控或錯失黃金煞停時機。因此，如何定義一套絕對安全的仲裁邏輯，確保緊急時能瞬間強制接管，並在危機解除後將控制權「無震盪」地交還，是多模組協同運作最大的技術挑戰。

6.2. 系統架構

本研究成功於 CARLA 模擬器中建立自動化且具可擴充性的閉環平台，並徹底解決了雙腦權限衝突，其完整的協同運作流程與系統架構如圖 22 系統架構圖所示。

在環境感知與特徵壓縮階段，系統運行時 CARLA 環境（CARLA Env）輸出的前視相機影像（Front Camera Image），會先進入圖中上方的變分自編碼器（Variational Auto Encode）進行特徵編碼（Encode）。壓縮後生成的潛在空間（Latent Space）向量，會連同環境回傳的車輛動態數據（Steer, Throttle, Speed），共同作為決策大腦的狀態輸入。 在主動巡航決策方面，於一般安全行駛狀態下，圖中右側的 PPO Agent 會根據上述接收到的 Latent Space 與環境狀態，並配合訓練過程中所設計的獎勵機制（Reward），持續輸出方向盤與油門訊號（Steer, Throttle）至 CARLA 物理引擎，執行平滑的自動巡航控制。最後，在 AEB 瞬間接管與安全閉環的機制上，圖中中央的純視覺 AEB 模組（包含 DVS 與 YOLO）會持續以高幀率接收環境的新狀態（New State）進行威脅評估。當 TTC 觸發緊急防護機制時，AEB 狀態機會取得最高優先級，直接輸出強制煞車指令（Break）至 CARLA 環境並瞬間接管控制權。待危機

解除後，狀態機即會恢復使用者原本狀態，將控制權平滑可靠地交還給 PPO 系統，藉此完整實現「環境感知 → 影像處理 → 決策訓練 → 模型回饋 → 車輛控制」的雙腦協同閉環系統。

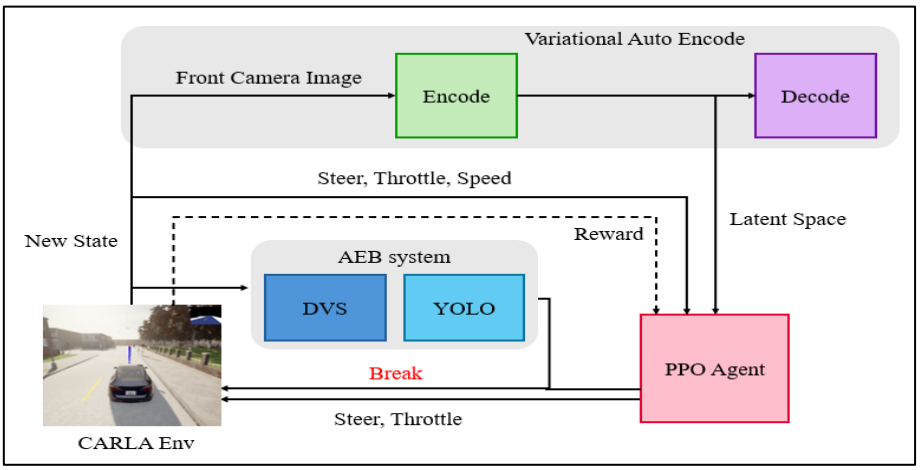


圖 22 系統架構圖

6.3. 結果呈現

圖 23 整合結果影片 QR-Code

柒、 結論

本專案以 CARLA 模擬環境為基礎，整合強化學習與純視覺感知兩大技術方向，建構出一套涵蓋車道置中、號誌狀態處理與自動緊急煞車的模擬自駕輔助系統。

在強化學習方面，本專案導入 Stable-Baselines3 模組中的 PPO (Proximal Policy Optimization) 演算法，建立從狀態到動作的決策流程（End-to-End）。我們設計了融合車輛動態與感知資訊的多維度狀態空間，並將模型輸出映射至油門、煞車與方向盤的連續型動作空間中，配合平滑處理減少車體震盪。同時，透過研發兼顧「車道置中維持」、「目標車速巡航」與「紅燈停車」的複合型獎勵函數，在目前模擬設定中觀察到循跡、速度控制與紅燈停車的成果。號誌資訊來自模擬器，結果也包含後處理的作用；跨路線、天候與車流的表現仍待驗證。

在 AEB 系統方面，本專題歷經 SNN 脈衝神經網路與 SpikeYOLO 的深入技術探索，自研輕量化 DVS 即時轉換算法（log 差分閾值觸發），最終以 YOLO（CNN）作為感知核心，在 13,340 張自建資料集上達到 mAP50 95%的偵測基礎。系統進一步整合針孔相機幾何測距（f = 480 px，車輛高度基準）、IoU 跨幀追蹤、分離式 EMA 雙濾波（α_dist = 0.2、α_speed = 0.05）TTC 遲滯狀態機（急煞 TTC < 3 s 或距離< 3 m、緩煞 TTC < 6 s、解除 TTC > 8 s 且距離> 4 m）與行駛走廊過濾及切入偵測，完整實現從感知到控制的閉環 AEB 功能，並搭配 IPM 鳥瞰圖儀表板提供直觀的全方位感知視覺化。

【結論與未來展望】綜合而言，雙模組的整合提供了協同控制的實作經驗，並在目前模擬設定中展示主動駕駛與被動防護銜接的可行性。雖然目前系統在極端場景的穩定性（RL 泛化能力限制）與感測器硬體天花板（單目測距誤差）方面仍有改善空間，但本研究已奠定良好的基礎。展望未來，本系統可進一步導入 LiDAR / GPS / IMU 進行多感測器融合以突破測距限制，或結合大型語言模型（LLM）進行高階語意決策推理，最終朝向邊緣運算架構實現真實車輛的即時部署，為次世代 ADAS 輔助駕駛系統提供了重要的技術根基與實作經驗。

捌、 參考文獻

[1]. E. Yurtsever *et al.*, "A survey of autonomous driving: Common practices and emerging technologies," 2023.

[2]. A. Dosovitskiy *et al.*, "CARLA: An open urban driving simulator," arXiv preprint arXiv:1711.03938, 2022.

[3]. C. Chen *et al.*, "End-to-end autonomous driving with deep reinforcement learning," 2022.

[4]. D. Gehrig *et al.*, "Feedback Control of Event Cameras," in *CVPR*, 2021, arXiv:2105.00409.

[5]. Z. Luo *et al.*, "SpikeYOLO: Spiking Neural Network for Object Detection with Event Vision," GitHub, 2024. [Online]. Available: https://github.com/BICLab/SpikeYOLO

[6]. Y. Hu *et al.*, "V2E: From Video Frames to Realistic DVS Events," in *CVPRW*, 2021.

[7]. idreesshaikh, "Autonomous-Driving-in-Carla-using-Deep-Reinforcement-Learning," GitHub, 2022. [Online]. Available: https://github.com/idreesshaikh/Autonomous-Driving-in-Carla-using-Deep-Reinforcement-Learning

[8]. A. Maté, "CARLA-SB3-RL-Training-Environment," GitHub. [Online]. Available: https://github.com/alberto-mate/CARLA-SB3-RL-Training-Environment